

广东工业大学2025实习实训

大数据千亿级离线数仓项目实战

目录

1.实训方案设计.....	2
2.实训实施方案设计.....	2
3.日程安排.....	9

一、实训方案设计

技术方向	实训周期	计划实训时间	实训地点
大数据千亿级离线数仓项目	10天	2025年7月7日-7月18日	线上

随着大数据技术的迅猛发展，数据仓库与数据分析的重要性日益凸显。在这一背景下，Hive 作为一种基于 Hadoop 的数据仓库工具，凭借其强大的数据处理能力，逐渐受到了广泛关注。Hive 基于 Hadoop 的分布式存储和计算框架，为大数据处理提供了高效、稳定的解决方案。

本次课程将深入剖析Hive的核心原理与架构，带领学员了解 Meta Store 服务的角色与功能，掌握HiveServer内置函数的使用方法。同时，课程还将涵盖自定义 UDF 和 UDAF 的开发技巧，以及数据压缩、存储格式、自动化脚本和常见性能优化等方面的知识。

此外，课程还将涉及大数据部署运维的关键技术，包括使用Cloudera Manager 进行集群管理，利用Sqoop 进行数据采集，以及通过 Hive进行数据分析等。同时，学员还将学习到如何利用拉链表实现历史数据快照，以及通过Oozie 结合 Shell 进行数据调度的方法。

通过本次课程的学习，学员将能够熟练掌握 Hive 的操作技巧，提升数据处理和分析的能力。同时，学员还将了解大数据部署运维的基本流程，为未来的职业发展奠定坚实基础。最终，学员将能够胜任基于 Hive 的大数据分析工程师等岗位，为企业或组织提供有力的数据支持。

二、实训实施方案设计

2.1 实训目标

- 掌握 Hive 核心技术
- 实现数据仓库搭建与运维
- 精通数据处理与分析
- 优化数据存储与调度
- 实现数据可视化与报表制作
- 培养项目管理与分析能力
- 提升沟通与表达能力

2.2实训内容

内容概览	
第一部分	Hive基础操作与数据类型
第二部分	Hive 高级特性
第三部分	Hive 原理与性能优化
第四部分	项目背景与需求分析
第五部分	大数据部署运维与数据仓库搭建
第六部分	数据采集与预处理
第七部分	数据分析与挖掘
第八部分	数据调度与存储优化
第九部分	数据可视化与报表制作
第十部分	项目总结与成果展示

2.3 实战项目

基于 Hive 的离线数仓还原经典

在当今数字化时代，大数据技术在各行各业的应用日益广泛，对数据的整合、分析和可视化提出了更高的要求。本项目旨在通过构建一套完整的数据分析体系，实现对咨询、意向用户、有效线索、报名用户及教学出勤等关键业务主题的深度洞察。

通过搭建高效稳定的数据仓库，本项目将实现对海量数据的存储与管理，为后续的数据分析提供坚实的基础。同时，我们将针对各业务主题，开发相应的数据分析模型，提取有价值的信息，为业务决策提供有力支持。

在数据可视化方面，我们将利用先进的 BI 工具，将分析结果以直观、易懂的方式呈现出来，帮助用户快速理解业务状况，发现潜在机会。通过本项目的实施，我们将为企业提供一套完整的数据分析解决方案，助力企业在激烈的市场竞争中取得优势。



三、日程安排

时间	名称	具体内容
第一天	Hive 基础操作与数据类型	1、Hive 环境搭建与基本配置。 2、HQL（Hive Query Language）基础语法。 3、数据类型详解：基本类型、复杂类型。 4、实际操作：创建表、插入数据、查询数据。
第二天	Hive 高级特性	1、分区表与分桶表的原理与应用。 2、临时表的创建与使用。 3、explain命令的使用，分析执行计划。 4、案例实践：使用分区和分桶优化查询性能
第三天	Hive 原理与性能优化	1、Hive 的工作原理与架构解析。 2、Meta Store 服务的作用与配置。 3、HiveServer 内置函数的使用。 4、自定义 UDF 和 UDAF 的开发。 5、数据压缩、存储格式的选择与配置。 6、常见性能优化技巧：如使用索引、调整参数等。
第四天	项目背景与需求分析	1、项目背景介绍。 2、需求分析：明确业务需求、数据来源、处理流程等。 3、项目目标与任务分配。
第五天	大数据部署运维与数据仓库搭建	1、使用 Cloudera Manager 部署 Hadoop 集群。 2、配置 Hive 服务，并验证其可用性。 3、创建基本的 Hive表，并插入测试数据。
第六天	数据采集与预处理	1、使用 Sqoop 从关系型数据库导入数据到 Hive。 2、学习数据清洗、转换和格式化的基本方法。 3、对导入的数据进行初步预处理，以满足分析需求
第七天	数据分析与挖掘	1、编写 Hive SQL 语句，实现数据的聚合、关联和筛选等操作。 2、学习数据挖掘的基本算法，如分类、聚类、关联规则挖掘等。 3、结合实际案例，应用数据挖掘算法进行分析。
第八天	数据调度与存储优化	1、使用 Oozie 定义工作流，实现数据的定时调度和自动化处理。 2、习 Hive 的存储格式，如 ORC、Parquet 等，并进行优化配置。 3、监控 Hive 任务的执行情况，进行性能调优。

第九天	数据可视化与报表制作	1、使用 FineBI 连接 Hive 数据源，进行数据抽取和转换。 2、设计并制作各类报表和仪表盘，如趋势图、柱状图、饼图等。 3、对报表进行美化和布局调整，提升用户体验。
第十天	项目总结与成果展示	1、回顾项目整体流程，总结遇到的问题和解决方案。 2、分享在项目中学到的知识和技能，以及个人成长体会。 3、展示项目成果，包括数据仓库、数据分析报告、可视化仪表盘等。