

第一章 最优化理论基础

1、验证下列集合是凸集：

$$(1) \quad S = \{(x_1, x_2) \mid 2x_1 + x_2 \geq 1, x_1 - 2x_2 \geq 1\}.$$

$$(2) \quad S = \{(x_1, x_2) \mid x_1^2 + x_2^2 \leq 1\}.$$

$$(3) \quad S = \{(x_1, x_2) \mid |x_2| \leq x_1\}.$$

证 (1) 对集合 S 中任意两点 $x^{(1)} = \begin{bmatrix} x_1^{(1)} \\ x_2^{(1)} \end{bmatrix}, x^{(2)} = \begin{bmatrix} x_1^{(2)} \\ x_2^{(2)} \end{bmatrix}$ 及每个数 $\lambda \in [0,1]$, 有

$$\lambda x^{(1)} + (1-\lambda)x^{(2)} = \begin{bmatrix} \lambda x_1^{(1)} + (1-\lambda)x_1^{(2)} \\ \lambda x_2^{(1)} + (1-\lambda)x_2^{(2)} \end{bmatrix}.$$

由题设, 有

$$\begin{aligned} & [\lambda x_1^{(1)} + (1-\lambda)x_1^{(2)}] + 2[\lambda x_2^{(1)} + (1-\lambda)x_2^{(2)}] \\ &= \lambda(x_1^{(1)} + 2x_2^{(1)}) + (1-\lambda)(x_1^{(2)} + 2x_2^{(2)}) \geq \lambda + (1-\lambda) = 1, \\ & [\lambda x_1^{(1)} + (1-\lambda)x_1^{(2)}] - [\lambda x_2^{(1)} + (1-\lambda)x_2^{(2)}] \\ &= \lambda(x_1^{(1)} - x_2^{(1)}) + (1-\lambda)(x_1^{(2)} - x_2^{(2)}) \geq \lambda + (1-\lambda) = 1. \end{aligned}$$

因此, $\lambda x^{(1)} + (1-\lambda)x^{(2)} \in S$, 故 S 是凸集。

(2) 对集合 S 中任意两点 $x^{(1)} = \begin{bmatrix} x_1^{(1)} \\ x_2^{(1)} \end{bmatrix}, x^{(2)} = \begin{bmatrix} x_1^{(2)} \\ x_2^{(2)} \end{bmatrix}$ 及每个数 $\lambda \in [0,1]$, 有

$$\lambda x^{(1)} + (1-\lambda)x^{(2)} = \begin{bmatrix} \lambda x_1^{(1)} + (1-\lambda)x_1^{(2)} \\ \lambda x_2^{(1)} + (1-\lambda)x_2^{(2)} \end{bmatrix}.$$

由题设, 有

$$\begin{aligned} & [\lambda x_1^{(1)} + (1-\lambda)x_1^{(2)}]^2 + [\lambda x_2^{(1)} + (1-\lambda)x_2^{(2)}]^2 \\ &= \lambda^2(x_1^{(1)})^2 + 2\lambda(1-\lambda)x_1^{(1)}x_1^{(2)} + (1-\lambda)^2(x_1^{(2)})^2 \\ &+ \lambda^2(x_2^{(1)})^2 + 2\lambda(1-\lambda)x_2^{(1)}x_2^{(2)} + (1-\lambda)^2(x_2^{(2)})^2 \\ &= \lambda^2[(x_1^{(1)})^2 + (x_2^{(1)})^2] + (1-\lambda)^2[(x_1^{(2)})^2 + (x_2^{(2)})^2] + \lambda(1-\lambda)[2x_1^{(1)}x_1^{(2)} + 2x_2^{(1)}x_2^{(2)}] \\ &\leq \lambda^2 + (1-\lambda)^2 + \lambda(1-\lambda)[(x_1^{(1)})^2 + (x_1^{(2)})^2 + (x_2^{(1)})^2 + (x_2^{(2)})^2] \\ &\leq \lambda^2 + (1-\lambda)^2 + 2\lambda(1-\lambda) \\ &= 1. \end{aligned}$$

因此, $\lambda x^{(1)} + (1-\lambda)x^{(2)} \in S$, 故 S 是凸集。

(3) 对集合 S 中任意两点 $x^{(1)} = \begin{bmatrix} x_1^{(1)} \\ x_2^{(1)} \end{bmatrix}, x^{(2)} = \begin{bmatrix} x_1^{(2)} \\ x_2^{(2)} \end{bmatrix}$ 及每个数 $\lambda \in [0,1]$, 有

$$\lambda x^{(1)} + (1-\lambda)x^{(2)} = \begin{bmatrix} \lambda x_1^{(1)} + (1-\lambda)x_1^{(2)} \\ \lambda x_2^{(1)} + (1-\lambda)x_2^{(2)} \end{bmatrix}.$$

由题设, 有

$$\lambda x_1^{(1)} + (1-\lambda)x_1^{(2)} \geq \lambda |x_1^{(1)}| + (1-\lambda)|x_1^{(2)}| \geq |\lambda x_1^{(1)} + (1-\lambda)x_1^{(2)}|.$$

因此, $\lambda x^{(1)} + (1-\lambda)x^{(2)} \in S$, 故 S 是凸集。

2、判断下列函数为凸(凹)函数或是严格凸(凹)函数:

$$(1) f(x) = x_1^2 + 2x_2^2.$$

$$(2) f(x) = 3x_1^2 - 6x_1x_2 + x_2^2.$$

$$(3) f(x) = x_1^2 - 2x_1x_2 + x_2^2 + 2x_1 + 3x_2.$$

$$(4) f(x) = 2x_1^2 + x_2^2 + 2x_3^2 + x_1x_2 - 3x_1x_3 + x_1 - x_3.$$

答 (1) 函数 $f(x)$ 的 Hesse 矩阵是

$$\nabla^2 f(x) = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}.$$

显然 $\nabla^2 f(x)$ 是正定矩阵, 因此 $f(x)$ 是一个严格凸函数。

(2) 函数 $f(x)$ 的 Hesse 矩阵是

$$\nabla^2 f(x) = \begin{bmatrix} 6 & -6 \\ -6 & 2 \end{bmatrix}.$$

显然 $\nabla^2 f(x)$ 是不定矩阵, 因此 $f(x)$ 不是凸函数。

(3) 函数 $f(x)$ 的 Hesse 矩阵是

$$\nabla^2 f(x) = \begin{bmatrix} 2 & -2 \\ -2 & 2 \end{bmatrix}.$$

显然 $\nabla^2 f(x)$ 是半正定矩阵，因此 $f(x)$ 是一个凸函数。

(4) 函数 $f(x)$ 的 Hesse 矩阵是

$$\nabla^2 f(x) = \begin{bmatrix} 4 & 1/2 & -3/2 \\ 1/2 & 2 & 0 \\ -3/2 & 0 & 6 \end{bmatrix}.$$

显然 $\nabla^2 f(x)$ 是正定矩阵，因此 $f(x)$ 是一个严格凸函数。

3. 证明 $f(x) = \frac{1}{2}x^T A x + b^T x$ 是严格凸函数当且仅当 Hesse 矩阵 A 正定。

证：先证必要性。设 $f(x) = \frac{1}{2}x^T A x + b^T x$ 是严格凸函数。根据一阶充要条件，对任意非零

向量 x 及 $\bar{x} = 0$ 。令 $\hat{x} = r \frac{x}{\|x\|}, r \in R$ ，有

$$f(\hat{x}) > f(0) + \nabla f(0)^T \hat{x}.$$

将 $f(\hat{x})$ 在 $\bar{x} = 0$ 处展开，有

$$f(\hat{x}) = f(0) + \nabla f(0)^T \hat{x} + \frac{1}{2} \hat{x}^T \nabla^2 f(0) \hat{x} + o(\|\hat{x}\|^2).$$

由上面两个式子得

$$\frac{1}{2} \hat{x}^T \nabla^2 f(0) \hat{x} + o(\|\hat{x}\|^2) > 0.$$

由于 $f(x)$ 是二次函数，所以 $\nabla^2 f(0) = A$ 。于是

$$\frac{1}{2} \hat{x}^T A \hat{x} + o(\|\hat{x}\|^2) > 0.$$

将 $\hat{x} = r \frac{x}{\|x\|}, r \in R$ 代入上式，得

$$\frac{r^2}{2} x^T A x + o(r^2) > 0.$$

即

$$x^T A x + 2 \frac{o(r^2)}{r^2} > 0.$$

令 $r \rightarrow 0$ ，得 $x^T A x > 0$ ，于是矩阵 A 正定。

再证充分性。设 A 正定，对任意两个不同点 x 及 $\bar{x}$ ，根据中值定理，有

$$\begin{aligned} f(x) &= f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + \frac{1}{2} (x - \bar{x})^T \nabla^2 f(\hat{x}) (x - \bar{x}) \\ &= f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + \frac{1}{2} (x - \bar{x})^T A (x - \bar{x}) \\ &> f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}). \end{aligned}$$

于是根据凸函数的一阶充要条件得， $f(x) = \frac{1}{2} x^T A x + b^T x$ 是严格凸函数。

4. 设 $f(x)$ 是定义在 R_n 上的函数，如果对每一点 $x \in R_n$ 及正数 t 均有 $f(tx) = tf(x)$ ，则称

$f(x)$ 为正齐次函数。证明 R_n 上的正齐次函数 $f(x)$ 为凸函数的充要条件是，对任何

$x^{(1)}, x^{(2)} \in R_n$ ，有

$$f(x^{(1)} + x^{(2)}) \leq f(x^{(1)}) + f(x^{(2)}).$$

证：先证必要性。设正齐次函数 $f(x)$ 为凸函数，则对任意两点 $x^{(1)}, x^{(2)} \in R_n$ ，必有

$$f\left(\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)}\right) \leq \frac{1}{2}f(x^{(1)}) + \frac{1}{2}f(x^{(2)}).$$

由 $f(x)$ 为正齐次函数，有

$$f\left(\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)}\right) = \frac{1}{2}(f(x^{(1)}) + f(x^{(2)})).$$

代入前式得

$$\frac{1}{2}f(x^{(1)} + x^{(2)}) \leq \frac{1}{2}f(x^{(1)}) + \frac{1}{2}f(x^{(2)}).$$

即

$$f(x^{(1)} + x^{(2)}) \leq f(x^{(1)}) + f(x^{(2)}).$$

再证充分性。设正齐次函数 $f(x)$ 对任意两点 $x^{(1)}, x^{(2)} \in R_n$ ，有

$$f(x^{(1)} + x^{(2)}) \leq f(x^{(1)}) + f(x^{(2)}).$$

对每个数 $\lambda \in (0,1)$ ，有

$$f(\lambda x^{(1)} + (1-\lambda)x^{(2)}) \leq f(\lambda x^{(1)}) + f((1-\lambda)x^{(2)}) = \lambda f(x^{(1)}) + (1-\lambda)f(x^{(2)}).$$

因此 $f(x)$ 为凸函数。

5. 设 $f(x) : R^3 \rightarrow R$ 定义为 $f(x) = (x_1 + 3x_2)^2 + 2(x_1 - x_3)^4 + (x_2 - 2x_3)^4$ 。证明

$x^* = (0,0,0)^T$ 是 $f(x)$ 的稳定点，并且 x^* 是 $f(x)$ 在 R^3 上的严格全局极小点。

证明：函数 $f(x)$ 的梯度是

$$\nabla f(x) = \begin{bmatrix} 2x_1 + 6x_2 + 8(x_1 - x_3)^3 \\ 6x_1 + 18x_2 + 4(x_1 - x_3)^3 \\ -8(x_1 - x_3)^3 - 8(x_2 - 2x_3)^3 \end{bmatrix}.$$

于是

$$\nabla f(x^*) = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

所以 $x^* = (0,0,0)^T$ 是 $f(x)$ 的稳定点。对于任意的 $x \in R^3$ ，且 $x \neq x^*$ ，显然有，

$$f(x) \geq 0 = f(x^*).$$

因此 x^* 是 $f(x)$ 在 R^3 上的全局极小点。假设 $f(x) = 0$ 。显然有

$$x_1 + 3x_2 = 0, x_1 - x_3 = 0, x_2 - 2x_3 = 0.$$

由此得 $x_1 = x_2 = x_3 = 0$ 。于是 $x = x^*$ ，这与 $x \neq x^*$ 矛盾。因此对于任意的 $x \in R^3$ ，且 $x \neq x^*$ ，有，

$$f(x) > f(x^*).$$

因此 x^* 是 $f(x)$ 在 R^3 上的严格全局极小点。

6. 设 $f(x): R^n \rightarrow R$ 是凸函数, $x^{(1)}, \dots, x^{(m)} \in R^n, \lambda_1, \dots, \lambda_m$ 是非负实数且 $\lambda_1 + \dots + \lambda_m = 1$ 。

证明 $f(\lambda_1 x^{(1)} + \dots + \lambda_m x^{(m)}) \leq \lambda_1 f(x^{(1)}) + \dots + \lambda_m f(x^{(m)})$ 。(Jensen's 不等式)

证明: 利用数学归纳法。当 $m=1$ 时, 显然成立。假设当 $m=k-1$ 时命题成立, 下证当 $m=k$ 时命题也成立。于是

$$\begin{aligned} & f(\lambda_1 x^{(1)} + \dots + \lambda_{k-1} x^{(k-1)} + \lambda_k x^{(k)}) \\ &= f\left(\sum_{i=1}^{k-1} \lambda_i \left(\frac{\lambda_1}{\sum_{i=1}^{k-1} \lambda_i} x^{(1)} + \dots + \frac{\lambda_{k-1}}{\sum_{i=1}^{k-1} \lambda_i} x^{(k-1)}\right) + \lambda_k x^{(k)}\right) \\ &\leq \sum_{i=1}^{k-1} \lambda_i f\left(\frac{\lambda_1}{\sum_{i=1}^{k-1} \lambda_i} x^{(1)} + \dots + \frac{\lambda_{k-1}}{\sum_{i=1}^{k-1} \lambda_i} x^{(k-1)}\right) + \lambda_k f(x^{(k)}) \\ &\leq \sum_{i=1}^{k-1} \lambda_i \left(\frac{\lambda_1}{\sum_{i=1}^{k-1} \lambda_i} f(x^{(1)}) + \dots + \frac{\lambda_{k-1}}{\sum_{i=1}^{k-1} \lambda_i} f(x^{(k-1)})\right) + \lambda_k f(x^{(k)}) \\ &= \lambda_1 f(x^{(1)}) + \dots + \lambda_{k-1} f(x^{(k-1)}) + \lambda_k f(x^{(k)}), \end{aligned}$$

其中第一个不等式是由 $f(x)$ 是凸函数得到的, 第二个不等式是根据归纳假设得到的。

7. 设 f, g 都是 R^n 上的凸函数, 证明 $f+g$ 及 $\max\{|f|, |g|\}$ 也是凸函数。

证明: 对于任意的 $x, y \in R^n, \lambda \in [0, 1]$, 由 f, g 都是 R^n 上的凸函数得

$$\begin{aligned} f(\lambda x + (1-\lambda)y) &\leq \lambda f(x) + (1-\lambda)f(y), \\ g(\lambda x + (1-\lambda)y) &\leq \lambda g(x) + (1-\lambda)g(y). \end{aligned}$$

于是

$$\begin{aligned} & (f+g)(\lambda x + (1-\lambda)y) \\ &= f(\lambda x + (1-\lambda)y) + g(\lambda x + (1-\lambda)y) \\ &\leq \lambda f(x) + (1-\lambda)f(y) + \lambda g(x) + (1-\lambda)g(y) \\ &= \lambda(f(x) + g(x)) + (1-\lambda)(f(y) + g(y)) \\ &= \lambda(f+g)(x) + (1-\lambda)(f+g)(y). \end{aligned}$$

因此 $f+g$ 是凸函数。令 $h = \max\{|f|, |g|\}$, 则

$$\begin{aligned}
& h(\lambda x + (1-\lambda)y) \\
&= \max\{|f|, |g|\}(\lambda x + (1-\lambda)y) \\
&= \max\{|f(\lambda x + (1-\lambda)y)|, |g(\lambda x + (1-\lambda)y)|\} \\
&\leq \max\{\lambda|f(x)| + (1-\lambda)|f(y)|, \lambda|g(x)| + (1-\lambda)|g(y)|\} \\
&\leq \max\{\lambda|f(x)|, \lambda|g(x)|\} + \max\{(1-\lambda)|f(y)|, (1-\lambda)|g(y)|\} \\
&= \lambda \max\{|f(x)|, |g(x)|\} + (1-\lambda) \max\{|f(y)|, |g(y)|\} \\
&= \lambda \max\{|f|, |g|\}(x) + (1-\lambda) \max\{|f|, |g|\}(y) \\
&= \lambda h(x) + (1-\lambda)h(y),
\end{aligned}$$

第二个不等式是根据最大化函数的如下性质得到的：

$$\max_i \{a_i + b_i\} \leq \max_i a_i + \max_i b_i.$$

因此 $\max\{|f|, |g|\}$ 是凸函数。

8. 设 $f(x) = x_1^2 + x_2^2 - \frac{1}{3}x_1^3$ ，证明 $f(x)$ 有严格局部极小点 $(0,0)^T$ 和鞍点 $(2,0)^T$ 。

证明：令 $x^{(1)} = (0,0)^T, x^{(2)} = (2,0)^T$ 。函数 $f(x)$ 的梯度是

$$\nabla f(x) = \begin{bmatrix} 2x_1 - x_1^2 \\ 2x_2 \end{bmatrix}.$$

于是

$$\nabla f(x^{(1)}) = \nabla f(x^{(2)}) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

因此 $x^{(1)}, x^{(2)}$ 都是 $f(x)$ 的稳定点。又 $f(x^{(1)}) = 0, f(x^{(2)}) = \frac{2}{3}$ 。函数 $f(x)$ 的 Hesse 矩阵是

$$\nabla^2 f(x) = \begin{bmatrix} 2-2x_1 & 0 \\ 0 & 2 \end{bmatrix}.$$

于是

$$\nabla^2 f(x^{(1)}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}, \nabla^2 f(x^{(2)}) = \begin{bmatrix} -2 & 0 \\ 0 & 2 \end{bmatrix}.$$

由 $\nabla^2 f(x^{(1)})$ 的正定性（数学分析多元函数极值的充分条件 $B^2 - AC = -4 < 0, A = 2 > 0$ ）

及最值的充分条件得， $(0,0)^T$ 是 $f(x)$ 的严格局部极小点。由数学分析多元函数极值的充分

条件 $B^2 - AC = 4 > 0$ 知, $(2,0)^T$ 不是 $f(x)$ 的极值点, 即是 $f(x)$ 的鞍点。

9. 设三个序列 $x_k = \left(\frac{1}{2}\right)^{2^k}$, $y_k = e^{-k \ln k}$, $z_k = \frac{1}{k^2}$, 当 $k \rightarrow \infty$, 它们均收敛于 0。试证 $\{x_k\}$ 二

阶收敛, $\{y_k\}$ 超线性收敛, $\{z_k\}$ 一阶收敛, 并画出三个序列的图形。

证明: 显然极限

$$\lim_{k \rightarrow \infty} \frac{x_{k+1}}{x_k^2} = \lim_{k \rightarrow \infty} \frac{\left(\frac{1}{2}\right)^{2^{k+1}}}{\left(\left(\frac{1}{2}\right)^{2^k}\right)^2} = 1.$$

于是 $\{x_k\}$ 是二阶收敛。又极限

$$\lim_{k \rightarrow \infty} \frac{y_{k+1}}{y_k} = \lim_{k \rightarrow \infty} \frac{e^{-(k+1) \ln(k+1)}}{e^{-k \ln k}} = \lim_{k \rightarrow \infty} e^{-(k+1) \ln(k+1) + k \ln k} = \lim_{k \rightarrow \infty} e^{-\ln(k+1) - k(\ln(k+1) - \ln k)} = 0.$$

于是 $\{y_k\}$ 是超线性收敛。又极限

$$\lim_{k \rightarrow \infty} \frac{z_{k+1}}{z_k} = \lim_{k \rightarrow \infty} \frac{\frac{1}{(k+1)^2}}{\frac{1}{k^2}} = \lim_{k \rightarrow \infty} \frac{k^2}{(k+1)^2} = \lim_{k \rightarrow \infty} \frac{1}{(1+1/k)^2} = 1.$$

因此 $\{z_k\}$ 是一阶收敛。

10. 设 $f(x_1, x_2) = 10 - 2(x_1^2 - x_2)^2$,

$$S = \{(x_1, x_2) \mid -1 \leq x_1 \leq 1, -1 \leq x_2 \leq 1\},$$

$f(x_1, x_2)$ 是否为 S 上的凸函数?

答: 函数 $f(x)$ 的梯度是

$$\nabla f(x) = \begin{bmatrix} 8(x_2 - x_1^2) \\ -4(x_2 - x_1^2) \end{bmatrix}.$$

于是函数 $f(x)$ 的 Hesse 矩阵是

$$\nabla^2 f(x) = \begin{bmatrix} 8(x_2 - 3x_1^2) & 8x_1 \\ 8x_1 & -4 \end{bmatrix}.$$

在点 $(0,1)$ 处的 Hesse 矩阵是

$$\begin{bmatrix} 8 & 0 \\ 0 & -4 \end{bmatrix}$$

是不定的, 因此 $\nabla^2 f(x)$ 在集合 S 上不是半正定矩阵, 因此 $f(x_1, x_2)$ 不是 S 上的凸函数。

补 1、设点列 $\{x_k\} \subseteq R^2$ 由下面定义

$$x_k = (1 + e^{-k^2}, 0.5^{2k})^T, k = 0, 1, 2, \dots$$

证明: 点列 $\{x_k\}$ 超线性收敛于 $(1,0)^T$ 。

证明: 根据指数函数的性质, 显然点列 $\{x_k\}$ 收敛于 $x^* = (1,0)^T$, 又

$$\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} = \lim_{k \rightarrow \infty} \frac{\sqrt{e^{-2(k+1)^2} + 0.5^{2^{k+2}}}}{\sqrt{e^{-2k^2} + 0.5^{2^{k+1}}}}$$

分析

$$\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|^2}{\|x_k - x^*\|^2} = \lim_{k \rightarrow \infty} \frac{e^{-2(k+1)^2} + 0.5^{2^{k+2}}}{e^{-2k^2} + 0.5^{2^{k+1}}} = \lim_{k \rightarrow \infty} \frac{e^{-4k-1} + e^{2k^2} / 2^{2^{k+2}}}{1 + e^{2k^2} / 2^{2^{k+1}}} = 0.$$

因此点列 $\{x_k\}$ 超线性收敛于 $(1,0)^T$ 。 解毕

是正定矩阵。

证明 $f(x)$ 的梯度是 $\nabla f(x) = Ax + b$ ，于是 $f(x)$ 是严格凸函数的充要条件是对于任意的

$x_1 \neq x_2$ ，有

$$\begin{cases} \nabla f(x_1)^T (x_2 - x_1) < f(x_2) - f(x_1) \\ \nabla f(x_2)^T (x_1 - x_2) < f(x_1) - f(x_2) \end{cases}$$

代入 $\nabla f(x_1) = Ax_1 + b, \nabla f(x_2) = Ax_2 + b$ ，并将上述两式相加得

$$(x_1 - x_2)^T A (x_1 - x_2) > 0.$$

由 $x_1 \neq x_2$ 的任意性，显然上面的不等式成立等价于 A 是正定矩阵。

补 7、考虑规划问题

$$\begin{cases} \min c^T x \\ \text{s.t. } g_i(x) \geq 0, i = 1, 2, \dots, m \\ Ax \geq b \end{cases}$$

其中 $g_i(x) (i = 1, 2, \dots, m)$ 为可微的凸函数；若 x_0 是该规划的一个可行解，且存在方向 d_0 满足

$$\begin{cases} \nabla g_i(x_0)^T d_0 \geq 0, i = 1, 2, \dots, m \\ Ad_0 \geq 0 \quad c^T d_0 < 0. \end{cases}$$

求证该规划的目标函数无下界。

证明 对 $\forall t > 0$ ，构造 $x_0 + td_0$ 。因为 $g_i(x)$ 是可微的凸函数， $g_i(x_0) \geq 0$ 且 $\nabla g_i(x_0)^T d_0 \geq 0$ ，

所以

$$g_i(x_0 + td_0) \geq g_i(x_0) + t \nabla g_i(x_0)^T d_0 \geq 0$$

并且 $A(x_0 + td_0) = Ax_0 + tAd_0 \geq b$ ，所以 $x_0 + td_0$ 是规划问题的可行解。同时由 t 的任意性，

目标函数值

$$c^T(x_0 + td_0) = c^T x_0 + tc^T d_0 \rightarrow -\infty (c^T d_0 < 0)$$

所以该规划的目标函数无下界。

补 8、 设 $A \in R_{n \times n}$ 是对称矩阵， $b \in R_n, c \in R$ ，求 $f(x) = \frac{1}{2} x^T A x + b^T x + c$ 在任意点 x 处

的梯度和 Hesse 矩阵。

解 $\nabla f(x) = Ax + b, \nabla^2 f(x) = A$ 。

补 9、 设 $\varphi(t) = f(x + td)$ ，其中 $f: R_n \rightarrow R$ 二阶可导， $x \in R_n, d \in R_n, t \in R$ ，试求 $\varphi''(t)$ 。

解 $\varphi'(t) = \nabla f(x + td)^T d, \varphi''(t) = d^T \nabla^2 f(x + td) d$.

补 10、设方向 $d \in R^n$ 是函数 $f(x)$ 在点 x 处的下降方向，令

$$H = I - \frac{dd^T}{d^T \nabla f(x)} - \frac{\nabla f(x) \nabla f(x)^T}{\nabla f(x)^T \nabla f(x)},$$

其中 I 为单位矩阵，证明方向 $p = -H \nabla f(x)$ 也是函数 $f(x)$ 在点 x 处的下降方向.

证明 由于方向 d 是函数 $f(x)$ 在点 x 处的下降方向，因此 $\nabla f(x)^T d < 0$ ，从而

$$\begin{aligned} \nabla f(x)^T p &= -\nabla f(x)^T H \nabla f(x) \\ &= -\nabla f(x)^T \left(I - \frac{dd^T}{d^T \nabla f(x)} - \frac{\nabla f(x) \nabla f(x)^T}{\nabla f(x)^T \nabla f(x)} \right) \nabla f(x) \\ &= -\nabla f(x)^T \nabla f(x) + \nabla f(x)^T d + \nabla f(x)^T \nabla f(x) \\ &= \nabla f(x)^T d < 0, \end{aligned}$$

所以，方向 p 是函数 $f(x)$ 在点 x 处的下降方向.

第二章 线搜索技术

1、用 0.618 法求解 $\min \phi(\alpha) = \alpha^2 - \alpha - 1$ ，初始区间 $[-1, 1]$ ，区间精度 $\delta = 0.05$ 。

解 **方法 1（迭代两次）**：令 $k = 0, \alpha_L^0 = -1, \alpha_U^0 = 1$ (搜索区间为 $[-1, 1]$, 长度为 2)，则

$$t_1^0 = \alpha_L^0 + (1 - 0.618) \times (\alpha_U^0 - \alpha_L^0) = -0.2361, t_2^0 = \alpha_L^0 + 0.618 \times (\alpha_U^0 - \alpha_L^0) = 0.2361,$$

于是

$$\phi(t_1^0) = -0.7082, \phi(t_2^0) = -1.1803。$$

第一次迭代 由于 $\phi(t_1^0) > \phi(t_2^0)$ ，所以令 $k = 1, \alpha_L^1 = t_1^0, \alpha_U^1 = \alpha_U^0, t_1^1 = t_2^0$ (搜索区间为

$[-0.2361, 1]$, 长度为 1.2361)。因此 $t_2^1 = \alpha_L^1 + 0.618 \times (\alpha_U^1 - \alpha_L^1) = 0.5279$ ，于是

$$\phi(t_2^1) = -1.2492。$$

第二次迭代 由于 $\phi(t_1^1) > \phi(t_2^1)$ ，所以令 $k = 2, \alpha_L^2 = t_1^1, \alpha_U^2 = \alpha_U^1, t_1^2 = t_2^1$ (搜索区间为

$[0.2361, 1]$, 长度为 0.7639)，因此 $t_2^2 = 0.7082$ ，于是

$$\phi(t_2^2) = -1.2067。$$

继续做，一直做到第 10 次迭代，搜索区间精度达到 0.05。

解 方法 1 (迭代两次): 令 $k = 0, \alpha_L^0 = 0, \alpha_U^0 = 4$ (搜索区间为 $[0, 4]$, 长度为 4), 则取 $\alpha^0 = 2$ 。

因此 $\phi(\alpha_L^0) = 2, \phi(\alpha^0) = -2, \phi(\alpha_U^0) = 42$ 。

第一次迭代

求过三点 $(\alpha_L^0, \phi(\alpha_L^0)), (\alpha^0, \phi(\alpha^0)), (\alpha_U^0, \phi(\alpha_U^0))$ 的抛物线 $\varphi(\alpha) = c\alpha^2 + b\alpha + a$ ，即

$$\begin{cases} c(\alpha_L^0)^2 + b\alpha_L^0 + a = \phi(\alpha_L^0) \\ c(\alpha^0)^2 + b\alpha^0 + a = \phi(\alpha^0) \\ c(\alpha_U^0)^2 + b\alpha_U^0 + a = \phi(\alpha_U^0) \end{cases}$$

求得该抛物线的顶点横坐标为 1.1667。因此 $\alpha_0^* = 1.1667, \phi(\alpha_0^*) = -3.4121$ 。比较得

$\alpha_0^* < \alpha^0, \phi(\alpha_0^*) < \phi(\alpha^0)$ ，于是令

$$k = 1, \alpha_L^1 = 0, \alpha^1 = \alpha_0^* = 1.1667, \alpha_U^1 = \alpha^0 = 2.$$

(搜索区间为 $[0, 2]$, 长度为 2)。

第二次迭代

求过三点 $(\alpha_L^1, \phi(\alpha_L^1)), (\alpha^1, \phi(\alpha^1)), (\alpha_U^1, \phi(\alpha_U^1))$ 的抛物线 $\varphi(\alpha) = c\alpha^2 + b\alpha + a$ ，即

1

4、用抛物线法求解 $\min_{x \geq 0} f(x) = x^3 - 2x + 1$ 的近似极小点，给定初始初始区间 $[0,3]$ ，初始

插值点 $x_0 = 1$ ，终止条件为 $|x_{k+1} - x_k| = \delta = 10^{-2}$ 。

解 修改函数 pwx2 中 a0=1 即可，然后在命令窗口中调用

```
[a1,phia1,k]=pwx2(inline('x^3-2*x+1'),0,3,1e-2)
```

得输出结果：

```
a1 =  
    0.8125  
phia1 =  
   -0.0886  
k =  
    4
```

5、分别用书上所给的 0.618 法和抛物线法 Matlab 程序计算下列问题的近似最优解：

(1) $\min f(x) = e^{-x} + x^2$;

(2) $\min f(x) = 3x^4 - 4x^3 - 12x^2$.

解 调用程序即可。

补 1、设 $f(x)$ 连续可微有下界，且 $\nabla f(x)$ Lipschitz 连续。设 $\{x_k\}$ 由采用 Armijo 型线

性搜索的迭代下降算法产生，且存在常数 $\eta > 0$ ，使得

$$\prod_{i=0}^k \cos \theta_i \geq \eta^k,$$

其中 θ_i 是搜索方向 $d_{(i)}$ 与负梯度方向 $-\nabla f(x_{(i)})$ 的夹角。证明：如果存在常数 $C > 0$ ，使得

$$\prod_{i=0}^k \|\nabla f(x_{(i)})\| \leq C \prod_{i=0}^k \|d_{(i)}\|$$

且搜索方向 $d_{(i)}$ 趋于 0 (原题没有这个条件，看一下是否可以去掉)，则有

$$\liminf_{k \rightarrow \infty} \|\nabla f(x_{(k)})\| = 0.$$

证明 (反证法) 假设命题不成立，则存在常数 $\varepsilon > 0$ ，使得 $\|\nabla f(x_{(k)})\| \geq \varepsilon, \forall k$ 。

如果 $\alpha_i = 1$ ，则由 Armijo 型线搜索的不等式得

$$f(x_{(i)}) - f(x_{(i+1)}) \geq -\rho \nabla f(x_{(i)})^T d_{(i)} = \rho \cos \theta_i \|\nabla f(x_{(i)})\| \|d_{(i)}\|. \quad (*)$$

如果 $\alpha_i < 1$ ，则由 Armijo 型线搜索的规则知 α_i / β 应该不满足 Armijo 不等式，即

$$f(x_{(i)} + \beta_{-1} \alpha_i d_{(i)}) > f(x_{(i)}) + \rho \beta_{-1} \alpha_i \nabla f(x_{(i)})^T d_{(i)}.$$

利用中值定理，存在 $\mu_i \in (0,1)$ ，使得

$$f(x_{(i)} + \beta_{-1} \alpha_i d_{(i)}) = f(x_{(i)}) + \rho \beta_{-1} \alpha_i \nabla f(x_{(i)} + \mu_i \beta_{-1} \alpha_i d_{(i)})^T d_{(i)}.$$

由上面两个式子得

$$(\nabla f(x_{(i)} + \mu_i \beta_{-1} \alpha_i d_{(i)}) - \nabla f(x_{(i)}))^T d_{(i)} \geq -(1 - \rho) \nabla f(x_{(i)})^T d_{(i)}.$$

结合 $\nabla f(x)$ 的 Lipschitz 连续性及 $\mu_i \in (0,1)$ ，可推得

$$\alpha_i \geq -\frac{(1 - \rho) \beta_{-1} \nabla f(x_{(i)})^T d_{(i)}}{L \|d_{(i)}\|^2}.$$

于是由 Armijo 型线搜索的不等式得

$$f(x_{(i)}) - f(x_{(i+1)}) \geq \rho c_1 \frac{(\nabla f(x_{(i)})^T d_{(i)})^2}{\|d_{(i)}\|^2} = \rho c_1 \cos^2 \theta_i \|\nabla f(x_{(i)})\|^2, \quad (**)$$

其中 $c_1 = (1 - \rho) \beta_{-1} L^{-1}$ 。由 (*) 和 (**)，存在常数 $c_2 = \min\{1, c_1\} > 0$ ，使得

$$f(x_{(i)}) - f(x_{(i+1)}) \geq c_2 \cos^2 \theta_i \min\{\|\nabla f(x_{(i)})\|, \|d_{(i)}\|\} \|\nabla f(x_{(i)})\|, \forall i.$$

于是，对于任意的 k ，有

$$\begin{aligned} \prod_{i=0}^{k-1} (f(x_{(i)}) - f(x_{(i+1)})) &\geq c \prod_{i=0}^{k-1} \cos_2 \theta \prod_{i=0}^{k-1} \min\{\varepsilon, \|d_{(i)}\|\} \varepsilon_k \\ &\geq c \eta_{2k} \varepsilon_k \prod_{i=0}^{k-1} \min\{\varepsilon, \|d_{(i)}\|\}. \end{aligned}$$

由搜索方向 $d_{(i)}$ 趋于 0 及上面的不等式得

$$\begin{aligned} \prod_{i=0}^{k-1} (f(x_{(i)}) - f(x_{(i+1)})) &\geq c \eta_{2k} \varepsilon_k \prod_{i=0}^{k-1} \|d_{(i)}\| \\ &\geq c \eta_{2k} \varepsilon_k \frac{1}{C_{k-1}} \prod_{i=0}^{k-1} \|\nabla f(x_{(i)})\| \\ &\geq c \frac{(\eta \varepsilon)^{2k}}{C_{k-1}} \equiv c_k. \end{aligned}$$

于是利用几何不等式得

$$c_3 \leq \left(\prod_{i=0}^{k-1} (f(x_{(i)}) - f(x_{(i+1)})) \right)^{1/k} \leq \frac{1}{k} \sum_{i=0}^{k-1} (f(x_{(i)}) - f(x_{(i+1)})) = \frac{f(x_{(0)}) - f(x_{(k)})}{k} \leq \frac{f(x_{(0)}) - M}{k},$$

其中 M 为 $f(x)$ 的下界。令 $k \rightarrow \infty$ ，得矛盾不等式 $c_3 \leq 0$ 。因此假设不成立。证毕

补 2、考虑如下优化问题：

$$\begin{aligned} \min f(x) &= x_1^2 + x_2^2 \\ \text{设 } x_{(0)} &= (1, 1)^T, d_{(0)} = (-1, -1)^T. \text{ 用 Armijo 搜索计算 } \alpha_0 = 0.5, \text{ 使得} \\ f(x_{(0)} + \alpha_0 d_{(0)}) &\leq f(x_{(0)}) + 0.9 \alpha_0 \nabla f(x_{(0)})^T d_{(0)}. \end{aligned}$$

用两种方法：(1) 直接解上面的不等式，仿照课件第 55 页的例题 2.2。

(2) 采用 Armijo 搜索的回溯步骤迭代求解。

第三章 最速下降法和牛顿法

1. 用最速下降法求 $f(x_1, x_2) = 3x_1^2 + 2x_2^2 - 4x_1 - 6x_2$ 的极小值。取初始点 $x_{(0)} = (1, 1)^T$ ，迭代两次。

解 $H = \begin{bmatrix} 6 & 0 \\ 0 & 4 \end{bmatrix}; b = \begin{bmatrix} -4 \\ -6 \end{bmatrix}; f(x_1, x_2)$ 的梯度是

$$\nabla f(x) = \begin{bmatrix} 6x_1 - 4 \\ 4x_2 - 6 \end{bmatrix}.$$

第一次迭代，从 $x_{(0)}$ 出发沿最速下降方向搜索，即方向

$$d_{(0)} = -\nabla f(x_{(0)}) = \begin{bmatrix} -2 \\ 2 \end{bmatrix}.$$

于是

$$x^{(0)} + \alpha d^{(0)} = \begin{bmatrix} 1-2\alpha \\ 1+2\alpha \end{bmatrix}.$$

取

$$\phi(\alpha) = f(x^{(0)} + \alpha d^{(0)}) = 3(1-2\alpha)^2 + 2(1+2\alpha)^2 - 4(1-2\alpha) - 6(1+2\alpha).$$

令 $\phi'(\alpha) = 40\alpha - 8 = 0$, 得

$$\alpha_0 = 1/5, x^{(1)} = x^{(0)} + \alpha_0 d^{(0)} = \begin{bmatrix} 3/5 \\ 7/5 \end{bmatrix}.$$

第二次迭代, 从 $x^{(1)}$ 出发沿最速下降方向搜索, 即方向

$$d^{(1)} = -\nabla f(x^{(1)}) = \begin{bmatrix} 2/5 \\ 2/5 \end{bmatrix}.$$

于是

$$x^{(1)} + \alpha d^{(1)} = \begin{bmatrix} 3/5 + 2\alpha/5 \\ 7/5 + 2\alpha/5 \end{bmatrix}.$$

取

$$\phi(\alpha) = f(x^{(1)} + \alpha d^{(1)}) = 4\alpha^2/5 - 8\alpha/25 - 29/5.$$

令 $\phi'(\alpha) = 8\alpha/5 - 8/25 = 0$, 得

$$\alpha_1 = 1/5, x^{(2)} = x^{(1)} + \alpha_1 d^{(1)} = \begin{bmatrix} 17/25 \\ 37/25 \end{bmatrix}.$$

目标值的下降性:

$$f(x^{(0)}) = -5, f(x^{(1)}) = -5.8000, f(x^{(2)}) = -5.8320 .$$

2. 分别用牛顿法和阻尼牛顿法求函数 $f(x_1, x_2) = 4x_1^2 + x_2^2 - 8x_1 - 4x_2$ 的极小点。任选初始点。

解 函数 $f(x_1, x_2)$ 的梯度和 Hesse 阵分别是

$$\nabla f(x) = \begin{bmatrix} 8x_1 - 8 \\ 2x_2 - 4 \end{bmatrix}, \nabla^2 f(x) = \begin{bmatrix} 8 & 0 \\ 0 & 2 \end{bmatrix}.$$

牛顿法: 选初始点 $x^{(0)} = (x_1^{(0)}, x_2^{(0)})^T$, 于是

$$\nabla f(x^{(0)}) = \begin{bmatrix} 8x_1^{(0)} - 8 \\ 2x_2^{(0)} - 4 \end{bmatrix}, \nabla^2 f(x) = \begin{bmatrix} 8 & 0 \\ 0 & 2 \end{bmatrix}.$$

情况 1: 如果 $x^{(0)} = (1, 2)^T$, 则 $\nabla f(x^{(0)}) = \begin{bmatrix} 8x_1^{(0)} - 8 \\ 2x_2^{(0)} - 4 \end{bmatrix} = 0$, 因此 $x^{(0)}$ 是函数 $f(x_1, x_2)$ 的一个稳定点。

又函数 $f(x_1, x_2)$ 显然是一个严格凸函数, 因此其稳定点也是其唯一的极小点。于是 $x^{(0)}$ 是函数 $f(x_1, x_2)$ 的最优解。

情况 2: 如果 $x^{(0)} \neq (1, 2)^T$, 则 $\nabla f(x^{(0)}) = \begin{bmatrix} 8x_1^{(0)} - 8 \\ 2x_2^{(0)} - 4 \end{bmatrix} \neq 0$, 因此

$$\begin{aligned} x^{(1)} &= x^{(0)} - (\nabla^2 f(x^{(0)}))^{-1} \nabla f(x^{(0)}) \\ &= \begin{bmatrix} x_1^{(0)} \\ x_2^{(0)} \end{bmatrix} - \begin{bmatrix} 1/8 & 0 \\ 0 & 1/2 \end{bmatrix} \begin{bmatrix} 8x_1^{(0)} - 8 \\ 2x_2^{(0)} - 4 \end{bmatrix} \\ &= \begin{bmatrix} x_1^{(0)} \\ x_2^{(0)} \end{bmatrix} - \begin{bmatrix} x_1^{(0)} - 1 \\ x_2^{(0)} - 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}. \end{aligned}$$

于是 $\nabla f(x^{(1)}) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ 。与情况一同样的道理, 此时 $x^{(1)}$ 是问题的最优解。

3. 用最速下降法程序求函数 $f(x_1, x_2) = (x_1 - 2)^4 + (x_1 - 2x_2)^2$ 的极小值。取初始点

$x^{(0)} = (0, 3)^T$ 。

解 首先建立两个分别计算目标函数和梯度的 m 文件:

```
function f=fun(x)
```

```
f=(x(1)-2)^4+(x(1)-2*x(2))^2;
```

```
function g=gfun(x)
```

```
g=[4*(x(1)-2)^3+2*(x(1)-2*x(2)), -4*(x(1)-2*x(2))];
```

然后再命令窗口调用如下命令:

```
x0=[0 3]';
```

```
[k,x,val]=grad('fun','gfun',x0,1e-5)
```

得到如下结果:

```
k =
```

```
2111
```

```
x =
```

```
2.0139
```

```
1.0070
```

```
val =
```

```
3.7685e-08
```

5. 设二次函数 $f(x) = \frac{1}{2}x^T Hx + b^T x$, 其中 H 是 n 阶对称正定矩阵。证明最速下降法求

$f(x)$ 的极小点时, 序列 $\{x_k\}$ 由 $x_{k+1} = x_k - \frac{g_k^T g_k}{g_k^T H g_k} g_k$ ($k=0, 1, 2, \dots$) 确立, 其中 x_0 为给定的

初始点, $g_k = Hx_k + b$ 。

证明 最速下降法迭代公式为

$$x_{k+1} = x_k - \alpha_k g_k \quad (k = 0, 1, 2, \dots)$$

其中 α_k 为从 x_k 出发, 沿方向 $d_k = -g_k$ 搜索的移动步长, 记

$$\phi(\alpha) = f(x_k - \alpha g_k),$$

则

$$\begin{aligned} \phi'(\alpha) &= \nabla f(x_k - \alpha g_k)^T (-g_k) \\ &= -[H(x_k - \alpha g_k) + b]^T \nabla f(x_k) \\ &= -[g_k - \alpha Hg_k]^T g_k. \end{aligned}$$

令 $\phi'(\alpha) = 0$, 解得步长

$$\alpha_k = \frac{g_k^T g_k}{g_k^T H g_k}.$$

于是

$$x_{k+1} = x_k - \frac{g_k^T g_k}{g_k^T H g_k} g_k \quad (k = 0, 1, 2, \dots).$$

6. 设目标函数 $f(x) = 4x_1^2 + x_2^2 - x_1^2 x_2$, 记 $x_a = (1, 1)^T, x_b = (3, 4)^T, x_c = (2, 0)^T$ 。

(1) 分别取初始点 $x_0^a = x_a, x_0^b = x_b$, 用标准的牛顿法计算前三次迭代。

(2) 注意序列 $\{x_k^a\}$ 和 $\{x_k^b\}$ 分别收敛到 $x_*^a = (0, 0)^T$ 和 $x_*^b = (2\sqrt{2}, 4)^T$, 证明 x_*^a 是 $f(x)$ 的极小点,

而 x_*^b 是 $f(x)$ 的鞍点。

(3) 取 $x_0^c = x_c$, 用牛顿法计算 x_1^c , 这将给出牛顿法失败的一种情形。

解 函数 $f(x)$ 的梯度和 Hesse 矩阵分别是

$$\nabla f(x) = \begin{pmatrix} 8x_1 - 2x_1 x_2 \\ 2x_2 - x_1^2 \end{pmatrix}, \nabla^2 f(x) = \begin{pmatrix} 8 - 2x_2 & -2x_1 \\ -2x_1 & 2 \end{pmatrix}$$

(1) 取初始点 $x_0^a = x_a$ 。

第一次迭代 在 x_0^a 处的梯度和 Hesse 矩阵分别是

$$\nabla f(x_0^a) = \begin{pmatrix} 6 \\ 1 \end{pmatrix}, \nabla^2 f(x_0^a) = \begin{pmatrix} 6 & -2 \\ -2 & 2 \end{pmatrix}$$

于是牛顿方向是

$$d_0^a = -(\nabla^2 f(x_0^a))^{-1} \nabla f(x_0^a) = -\begin{pmatrix} 6 & -2 \\ -2 & 2 \end{pmatrix}^{-1} \begin{pmatrix} 6 \\ 1 \end{pmatrix} = \begin{pmatrix} -7/4 \\ -9/4 \end{pmatrix}$$

从 x_0^a 沿 d_0^a 方向进行一维精确线搜索，得步长 $\alpha_0 = 0.5353$ 。因此

$$x_1^a = x_0^a + \alpha_0 d_0^a = (0.6662, 0.5709)^T。$$

第二次迭代 在 x_1^a 处的梯度和 Hesse 矩阵分别是

$$\nabla f(x_1^a) = \begin{pmatrix} 4.4422 \\ 0.8886 \end{pmatrix}, \nabla^2 f(x_1^a) = \begin{pmatrix} 6.6675 & -1.3325 \\ -1.3325 & 2 \end{pmatrix}$$

于是牛顿方向是

$$d_1^a = -(\nabla^2 f(x_1^a))^{-1} \nabla f(x_1^a) = \begin{pmatrix} -0.8710 \\ -1.0246 \end{pmatrix}$$

从 x_1^a 沿 d_1^a 方向进行一维精确线搜索，得步长 $\alpha_1 = 0.7128$ 。因此

$$x_2^a = x_1^a + \alpha_1 d_1^a = (0.0454, 0.1595)^T$$

取初始点 $x_0^b = x^b$ 。

(2) 在 x_*^a 处的梯度和 Hesse 矩阵分别是

$$\nabla f(x_*^a) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \nabla^2 f(x_*^a) = \begin{pmatrix} 8 & 0 \\ 0 & 2 \end{pmatrix}$$

显然矩阵 $\nabla^2 f(x_*^a)$ 正定，且 $\nabla f(x_*^a) = 0$ ，因此 x_*^a 是 $f(x)$ 的极小值点。

在 x_*^b 处的梯度和 Hesse 矩阵分别是

$$\nabla f(x_*^b) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \nabla^2 f(x_*^b) = \begin{pmatrix} 0 & -4\sqrt{2} \\ -4\sqrt{2} & 2 \end{pmatrix}$$

显然 $\nabla^2 f(x_*^b)$ 既不是半正定矩阵也不是半负定矩阵，因此 x_*^b 是 $f(x)$ 的鞍点。

(3) 第一次迭代 在 x_0^c 处的梯度和 Hesse 矩阵分别是

$$\nabla f(x_0^c) = \begin{pmatrix} 16 \\ -4 \end{pmatrix}, \nabla^2 f(x_0^c) = \begin{pmatrix} 8 & -4 \\ -4 & 2 \end{pmatrix}$$

显然矩阵 $\nabla^2 f(x_0^c)$ 不可逆，因此牛顿法失败。

7. 给定函数 $f(x) = (6 + x_1 + x_2)^2 + (2 - 3x_1 - 3x_2 - x_1x_2)^2$, 求在点 $x = (-4, 6)^T$ 处的最速下降方向和牛顿方向。

解 函数 $f(x)$ 的各阶偏导数为

$$\begin{aligned}\frac{\partial f(x)}{\partial x_1} &= 2(10x_1 + 8x_2 + 6x_1x_2 + 3x_1^2 + x_1x_2^2) \\ \frac{\partial f(x)}{\partial x_2} &= 2(8x_1 + 10x_2 + 6x_1x_2 + 3x_2^2 + x_2x_1^2) \\ \frac{\partial^2 f(x)}{\partial x_1^2} &= 2(10 + 6x_2 + x_2^2) \\ \frac{\partial^2 f(x)}{\partial x_1x_2} &= 2(8 + 6x_1 + 6x_2 + 2x_1x_2) \\ \frac{\partial^2 f(x)}{\partial x_2^2} &= 2(10 + 6x_1 + x_1^2).\end{aligned}$$

于是, 在点 $x = (-4, 6)^T$ 处的最速下降方向是

$$d = -\nabla f(\bar{x}) = \begin{bmatrix} 344 \\ -56 \end{bmatrix}.$$

Hesse 矩阵及其逆矩阵分别为

$$\nabla^2 f(x) = \begin{bmatrix} 164 & -56 \\ -56 & 4 \end{bmatrix}, [\nabla^2 f(x)]^{-1} = -\frac{1}{2480} \begin{bmatrix} 4 & 56 \\ 56 & 164 \end{bmatrix}.$$

因此牛顿方向为

$$d = -[\nabla^2 f(x)]^{-1} \nabla f(x) = \begin{bmatrix} 22/31 \\ -126/31 \end{bmatrix}.$$

8. 考虑函数 $f(x) = x_1^2 + 4x_2^2 - 4x_1 - 8x_2$.

- (1) 证明若从 $x_0 = (0, 0)^T$ 出发, 用最速下降法求极小点 $\bar{x}$, 则不能经有限步达到 $\bar{x}$;
- (2) 是否存在 x_0 , 使得从 x_0 出发, 用最速下降法求 $f(x)$ 的极小点经有限步迭代即可收敛?

答 对函数 $f(x)$ 最等价变形得

$$f(x) = (x_1 - 2)^2 + 4(x_2 - 1)^2 - 8.$$

因此 $f(x)$ 的极小点 $x = (2, 1)^T$, 极小值等于 -8.

- (1) 证明 (反证法) 假设从 $x_0 = (0, 0)^T$ 出发, 经有限步即可达到点 $\bar{x}$, 则存在一个迭代点

$\hat{x} = (\hat{x}_1, \hat{x}_2)^T \neq \bar{x}$, 使得 $\bar{x} = \hat{x} - \alpha g(\hat{x})$, 即

$$\begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} \hat{x}_1 \\ \hat{x}_2 \end{bmatrix} - \alpha \begin{bmatrix} 2(\hat{x}_1 - 2) \\ 8(\hat{x}_2 - 1) \end{bmatrix}, \alpha > 0.$$

经整理得方程组

$$\begin{cases} (1 - 2\alpha)\hat{x}_1 + 4\alpha - 2 = 0, \\ (1 - 8\alpha)\hat{x}_2 + 8\alpha - 1 = 0. \end{cases}$$

下面分 3 种情况讨论:

若 $\alpha = \frac{1}{2}$, 则 $\hat{x} = \begin{bmatrix} \hat{x}_1 \\ 1 \end{bmatrix}$, 梯度 $g(\hat{x}) = \begin{bmatrix} 2(\hat{x}_1 - 2) \\ 0 \end{bmatrix} \neq 0$. 显然, $g(\hat{x})$ 与 $g(x_0) = \begin{bmatrix} -4 \\ -8 \end{bmatrix}$ 既不

正交, 也不共线, 这是不可能的 (考虑最速下降法前后搜索方向的正交性), 因此 $\alpha \neq \frac{1}{2}$ 。

若 $\alpha = \frac{1}{8}$, 则 $\hat{x} = \begin{bmatrix} 2 \\ \hat{x}_2 \end{bmatrix}$, 梯度 $g(\hat{x}) = \begin{bmatrix} 0 \\ 8(\hat{x}_2 - 1) \end{bmatrix} \neq 0$. 显然, $g(\hat{x})$ 与 $g(x_0) = \begin{bmatrix} -4 \\ -8 \end{bmatrix}$ 既

不正交, 也不共线, 这是不可能的 (考虑最速下降法前后搜索方向的正交性), 因此 $\alpha \neq \frac{1}{8}$ 。

若 $\alpha \neq \frac{1}{2}$ 且 $\alpha \neq \frac{1}{8}$, 则 $\hat{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \bar{x}$, 这与 $\hat{x} \neq \bar{x}$ 矛盾。

(2) 函数 $f(x)$ 的梯度是

$$\nabla f(x) = \begin{bmatrix} 2x_1 - 4 \\ 8x_2 - 8 \end{bmatrix}.$$

(受第 9 题 (2) 的启发) 取点 $x^{(0)} = (2, 0)^T$, 则从 $x^{(0)}$ 出发沿最速下降方向搜索, 即方向

$$d^{(0)} = -\nabla f(x^{(0)}) = \begin{bmatrix} 0 \\ 8 \end{bmatrix}.$$

于是

$$x^{(0)} + \alpha d^{(0)} = \begin{bmatrix} 2 \\ 8\alpha \end{bmatrix}.$$

取

$$\phi(\alpha) = f(x^{(0)} + \alpha d^{(0)}) = 256\alpha^2 - 64\alpha - 4.$$

令 $\phi'(\alpha) = 512\alpha - 64 = 0$, 得

$$\alpha_0 = 1/8, x^{(1)} = x^{(0)} + \alpha_0 d^{(0)} = \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \bar{x}.$$

9. 设函数 $f(x) = \frac{1}{2}x^T Hx + b^T x$, 其中 H 对称正定。又设 $x_0 (\neq \bar{x})$ 可表示成 $x_0 = \bar{x} + \mu d$, 其中

$\bar{x}$ 为 $f(x)$ 的极小点, d 为 H 的属于特征值 λ 的特征向量。证明

$$(1) \nabla f(x_0) = \mu \lambda d;$$

(2) 如果从 $x_0 (\neq \bar{x})$ 出发, 沿最速下降方向做精确一维搜索, 则一步迭代达到极小点 $\bar{x}$ 。

证明: (1) 显然

$$\nabla f(x_0) = Hx_0 + b = H(\bar{x} + \mu d) + b = (H\bar{x} + b) + \mu Hd.$$

由于 $\bar{x}$ 为 $f(x)$ 的极小点, 故 $\nabla f(\bar{x}) = H\bar{x} + b = 0$. 又 $Hd = \lambda d$, 因此

$$\nabla f(x_0) = \mu \lambda d.$$

(2) 从 $x_0 (\neq \bar{x})$ 出发, 沿最速下降方向做精确一维搜索, 并结合 (1) 中结论, 有

$$x_1 = x_0 - \alpha_0 \nabla f(x_0) = \bar{x} + \mu d - \alpha_0 (\mu \lambda d) = \bar{x} + (1 - \alpha_0 \lambda) \mu d.$$

由于 H 是对称正定矩阵, 因此特征值 $\lambda > 0$ 。易得步长 $\alpha_0 = \frac{1}{\lambda}$ (由第 5 题解释也可), 于是

$$x_1 = \bar{x}. (\alpha_0 = \frac{g_0^T g_0}{g_0^T H g_0} = \frac{(\mu \lambda)^2 d^T d}{(\mu \lambda)^2 d^T H d} = \frac{(\mu \lambda)^2 d^T d}{(\mu \lambda)^2 \lambda d^T d} = \frac{1}{\lambda}.)$$

补充:

1、试用最速下降法求 $f(x) = (x_1 - 1)^2 + (x_2 - 1)^2$ 的极小点, 精度 $\varepsilon = 0.1$ 。

解: 取初始迭代点 $x_0 = (0, 0)^T$, 则 $g(x_0) = (-2, -2)^T$, 因此 $\|g(x_0)\| = 2\sqrt{2} > \varepsilon$ 。又

$$H(x) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}, \text{ 于是精确步长}$$

$$\alpha_0 = \frac{g_0^T g_0}{g_0^T H(x_0) g_0} = \frac{1}{2}.$$

因此 $x_1 = x_0 - \alpha_0 g_0 = (1, 1)^T$, $g(x_1) = (0, 0)^T$, 于是 $\|g(x_1)\| = 0 < \varepsilon$ 。

2、试用最速下降法求 $f(x) = 2x_1^2 + 2x_1 x_2 + 2x_2^2 - 4x_1 - 6x_2$ 的极小点, 精度 $\varepsilon = 0.1$ 。

解: 函数 $f(x)$ 的梯度和 Hesse 矩阵分别是

$$g(x) = \nabla f(x) = (4x_1 + 2x_2 - 4, 2x_1 + 4x_2 - 6)^T, H(x) = \nabla^2 f(x) = \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}.$$

取初始迭代点 $x_0 = (1, 1)^T$ ，于是 $\nabla f(x_0) = (2, 0)^T$ 。

第一次迭代：下一个迭代点 $x_1 = x_0 - \frac{g_0^T g_0}{g_0^T H(x_0) g_0} g_0 = x_0 - \frac{1}{4} g_0 = \left(\frac{1}{2}, 1\right)^T$ 。

第二次迭代： $g_1 = (0, 1)^T$ ，下一个迭代点 $x_2 = x_1 - \frac{g_1^T g_1}{g_1^T H(x_1) g_1} g_1 = x_1 - \frac{1}{4} g_1 = \left(\frac{1}{2}, \frac{5}{4}\right)^T$ 。

第三次迭代： $g_2 = \left(-\frac{1}{2}, 0\right)^T$ ，下一个迭代点

$$x_3 = x_2 - \frac{g_2^T g_2}{g_2^T H(x_2) g_2} g_2 = x_2 - \frac{1}{4} g_2 = \left(\frac{3}{8}, \frac{5}{4}\right)^T.$$

第四次迭代： $g_3 = \left(0, \frac{1}{4}\right)^T$ ，下一个迭代点

$$x_4 = x_3 - \frac{g_3^T g_3}{g_3^T H(x_3) g_3} g_3 = x_3 - \frac{1}{4} g_3 = \left(\frac{3}{8}, \frac{21}{16}\right)^T.$$

第五次迭代： $g_4 = \left(-\frac{1}{8}, 0\right)^T$ ，下一个迭代点

$$x_5 = x_4 - \frac{g_4^T g_4}{g_4^T H(x_4) g_4} g_4 = x_4 - \frac{1}{4} g_4 = \left(\frac{11}{32}, \frac{21}{16}\right)^T.$$

第六次迭代： $g_5 = \left(0, \frac{1}{16}\right)^T$ ，于是 $\|g_5\| = \frac{1}{16} < 0.1$ 。停止。取 x_5 作为近似最优解，输出 x_5 。

另外，用解析方法可以求得该问题的最优解为 $x^* = \left(\frac{1}{3}, \frac{4}{3}\right)^T$ 。

补 2、取初始点 $x_0 = (2, 1)^T$ 。用采用精确线性搜索的最速下降法求解下面的最优化问题

$$\min f(x) = \frac{1}{2} x_1^2 + x_2.$$

证明：(1)产生的点列 $\{x_k\}$ 的通项是 $x_{(k)} = \begin{pmatrix} 1 \\ 3 \end{pmatrix}^k \begin{pmatrix} 2 \\ (-1)_k \end{pmatrix}$ 。

(2)产生的点列 $\{x_k\}$ 满足 $\|x_{(k)} - x^*\| = \frac{1}{3^k} \|x_{(0)} - x^*\|$, 其中 x^* 为 $f(x)$ 的极小值点。

证明: (1) 直接计算得 $\nabla f(x) = (x_1, 2x_2)^T$ 。最速下降方向为

$$d = (d_1, d_2)^T = -\nabla f(x) = -(x_1, 2x_2)^T.$$

令

$$\phi(\alpha) = f(x + \alpha d) = \frac{1}{2} (x_1 + \alpha d_1)^2 + (x_2 + \alpha d_2)^2.$$

由 $\phi'(\alpha) = 0$ 得 $\phi(\alpha)$ 的最小值点(即精确搜索的步长)为

$$\alpha = -\frac{x_1 d_1 + 2x_2 d_2}{d_1^2 + 2d_2^2} = -\frac{x_1 + 4x_2}{x_1 + 8x_2}.$$

从而

$$\begin{aligned} x_{(k+1)} &= x_{(k)} + \alpha_k d_{(k)} = x_{(k)} - \frac{(x_{(k)})_2 + 4(x_{(k)})_1}{(x_{(k)})_1 + 8(x_{(k)})_2} \nabla f(x_{(k)}) \\ &= \left(\frac{4}{t_2 + 8} x_{(k)_1}, -\frac{t_2}{t_2 + 8} x_{(k)_2} \right)^T, \end{aligned}$$

其中 $t_k = |x_{(k)_1} / x_{(k)_2}|$ 。因此不难证明, 最速下降算法产生的点列如下

$$x_{(k)} = \left(\frac{1}{3} \right)^k \begin{pmatrix} 2 \\ (-1)^k \end{pmatrix}, k = 0, 1, 2, \dots$$

易知 $\{x_k\} \rightarrow x^* = 0$, 即算法产生的点列收敛于问题的解。

(2)显然

$$\|x_{(k)} - x^*\| = \|x_{(k)}\| = \left(\frac{1}{3} \right)^k \sqrt{5} = \frac{1}{3} \left(\frac{1}{3} \right)^{k-1} \sqrt{5} = \frac{1}{3} \|x_{(k-1)}\| = \frac{1}{3} \|x_{(k-1)} - x^*\|.$$

反复利用上式得

$$\|x_{(k)} - x^*\| = \frac{1}{3^k} \|x_{(0)} - x^*\|.$$

证毕

补 3、对于二次多元函数 $f(x) = \frac{1}{2} x^T Q x + q^T x$, 其中 Q 为 n 阶对称正定实矩阵, q 为 n 维

列向量, 证明:

$$f(x_{k+1}) - f(x^*) = \frac{1}{2} \|x - x^*\|_Q^2,$$

其中 x^* 为 $f(x)$ 的极小值点, $\|x\|_Q = \sqrt{x^T Q x}$ 。

证明: 利用 x^* 的最优性得 $Qx^* + q = 0$, 即 $q = -Qx^*$ 。于是

$$\begin{aligned} f(x) - f(x^*) &= \frac{1}{2} x^T Q x + q^T x - \frac{1}{2} (x^*)^T Q x^* - q^T x^* \\ &= \frac{1}{2} x^T Q x - \frac{1}{2} x^T Q x^* + \frac{1}{2} x^T Q x^* - \frac{1}{2} (x^*)^T Q x^* + q^T x - q^T x^* \\ &= \frac{1}{2} x^T Q (x - x^*) + \frac{1}{2} (x^*)^T Q (x - x^*) - x^T Q x^* + (x^*)^T Q x^* \\ &= \frac{1}{2} x^T Q (x - x^*) + \frac{1}{2} (x^*)^T Q (x^* - x) \\ &= \frac{1}{2} (x - x^*)^T Q (x - x^*) \\ &= \frac{1}{2} \|x - x^*\|_Q^2. \end{aligned}$$

证毕

补 4、 考虑无约束优化问题 $\min f(x) = \frac{a}{2} \|x\|^2 + b^T x + c$, 其中 $a > 0$ 。证明用精确线搜索的最速

下降法至多一步就可求得其最优解。

证明 设初始点为 x_0 , 则 $d_0 = -\nabla f(x_0) = -(ax_0 + b)$ 。

如果 $d_0 = 0$, 则 $\nabla f(x_0) = 0$ 。由于 $f(x)$ 是凸函数, 此时 x_0 是问题的最优解。

如果 $d_0 \neq 0$, 则精确线搜索的步长由下式给出

$$\alpha_0 = -\frac{\nabla f(x_0)^T d_0}{d_0^T d_0} = \frac{1}{a}.$$

于是

$$x_1 = x_0 + \alpha_0 d_0 = x_0 - \frac{1}{a}(ax_0 + b) = -\frac{b}{a}.$$

由 $\nabla f(x_1) = 0$ 。由于 $f(x)$ 是凸函数, 此时 x_1 是问题的最优解。

补 5、 考虑严格凸二次函数 $f(x) = \frac{1}{2} x^T Q x + q^T x$, 其中 $Q \in R^{n \times n}$ 对称正定。证明从任意初始点

x_0 出发, 采用精确线搜索的阻尼牛顿法最多经过一步迭代即可达到 $f(x)$ 的最小值点。

证明 经计算易得

$$\nabla f(x) = Qx + q, \nabla^2 f(x) = Q.$$

因此, 牛顿方向

$$d_0 = -(\nabla^2 f(x_0))^{-1} \nabla f(x_0) = -Q^{-1} \nabla f(x_0).$$

如果 $d_0 = 0$, 则 $\nabla f(x_0) = 0$ 。由于 $f(x)$ 是凸函数, 此时 x_0 是问题的最优解。

如果 $d_0 \neq 0$, 则精确线搜索的步长由下式给出

$$\alpha_0 = -\frac{\nabla f(x_0)^T d_0}{d_0^T Q d_0} = \frac{\nabla f(x_0)^T Q^{-1} \nabla f(x_0)}{\nabla f(x_0)^T Q^{-1} \nabla f(x_0)} = 1.$$

由此得

$$x_1 = x_0 + \alpha_0 d_0 = x_0 + d_0 = x_0 - Q^{-1}(Qx_0 + q) = -Q^{-1}q.$$

由 $\nabla f(x_1) = 0$ 。由于 $f(x)$ 是凸函数，此时 x_1 是问题的最优解。

补 6、Barzilai 和 Borwein(1988 年)提出两点步长梯度法，其基本思想是利用迭代当前点以及前一点的信息来确定步长因子。最速下降法的迭代公式 $x_{k+1} = x_k - \alpha_k g_k$ 可以改写成 $x_{k+1} = x_k - D_k g_k$ ，其中 $D_k = \alpha_k I$ 。然后通过下式来计算步长 α_k ，即矩阵 D_k 满足如下性质

$$\min \|s_{k-1} - D_k y_{k-1}\|$$

或

$$\min \|D_k^{-1} s_{k-1} - y_{k-1}\|$$

其中

$$s_{k-1} = x_k - x_{k-1}, y_{k-1} = g_k - g_{k-1}$$

(1)证明：通过上面两个优化问题得到的步长是

$$\alpha_k = \frac{s_{k-1}^T y_{k-1}}{\|y_{k-1}\|^2} \text{ 或 } \alpha_k = \frac{\|s_{k-1}\|^2}{s_{k-1}^T y_{k-1}}$$

(2)根据(1)得到两种 BB 算法(注意第一步仍用最速下降法的迭代策略)

$$x_{k+1} = \begin{cases} x_k - \alpha_k g_k, & k = 0 \\ x_k - \frac{s_{k-1}^T y_{k-1}}{\|y_{k-1}\|^2} g_k, & k \geq 1 \end{cases}$$

或

$$x_{k+1} = \begin{cases} x_k - \alpha_k g_k, & k = 0 \\ x_k - \frac{\|s_{k-1}\|^2}{s_{k-1}^T y_{k-1}} g_k, & k \geq 1 \end{cases}$$

运用这两种方法与最速下降法来求解 $f(x_1, x_2) = 100x_1^2 + x_2^2$ ，比较哪种方法的数值效果更好，

并将计算结果画图，初始点选为 $x^{(0)} = (1, 100)^T$ ，迭代终止条件是 $\|g_k\| < 10^{-5}$ 或 $k > 20$ 。

第四章 共轭梯度法

1、证明向量 $\alpha_1 = (1,0)^T$ 和 $\alpha_2 = (3,-2)^T$ 关于矩阵

$$A = \begin{bmatrix} 2 & 3 \\ 3 & 5 \end{bmatrix}$$

共轭。

证明 由于

$$\alpha_1^T A \alpha_2 = (1,0) \begin{bmatrix} 2 & 3 \\ 3 & 5 \end{bmatrix} \begin{bmatrix} 3 \\ -2 \end{bmatrix} = 0$$

因此命题成立。

2、给定

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 5 \end{bmatrix}, B = \begin{bmatrix} 1 & -1 & 0 \\ -1 & 2 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

试关于矩阵 A 和 B 各求出一组共轭方向。

解 利用第 8 题的方法，可以求出如下结果

$$\begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 7 \\ -3 \end{bmatrix} \text{ 关于 } A \text{ 共轭}, \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \text{ 关于 } B \text{ 共轭}.$$

3、设 $f(x) = \frac{1}{2}x^T Hx + b^T x$ ，其中

$$H = \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix}, b = \begin{bmatrix} 3 \\ 3 \end{bmatrix}.$$

(1) 证明 $d_0 = (1, 0)^T$ 与 $d_1 = (1, -2)^T$ 关 H 共轭。

(2) 以 $x_0 = (0, 0)^T$ 为初始点， d_0, d_1 为搜索方向，用精确线搜索求 $f(x)$ 的极小点。

解 (1) 因为 $d_0^T A d_1 = (1, 0) \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 1 \\ -2 \end{bmatrix} = 0$ ，所以 d_0 与 d_1 关 H 共轭。

(2) (注意这里不要求方向必须是下降方向，只要求是共轭方向即可。因此，步长的搜索区间是整个实数轴) 令 $x_1 = x_0 + \alpha d_0$ ，于是

$$\phi(\alpha) = f(x_0 + \alpha d_0) = \frac{1}{2}(x_0 + \alpha d_0)^T H(x_0 + \alpha d_0) + b^T(x_0 + \alpha d_0) = 2\alpha^2 + 3\alpha.$$

于是 $\alpha_0 = -3/4, x_1 = x_0 + \alpha_0 d_0 = (-3/4, 0)^T$ 。令 $x_2 = x_1 + \alpha d_1$ ，于是

$$\phi(\alpha) = f(x_1 + \alpha d_1) = \frac{1}{2}(x_1 + \alpha d_1)^T H(x_1 + \alpha d_1) + b^T(x_1 + \alpha d_1) = 6\alpha^2 + 3\alpha - 9/8$$

于是 $\alpha_1 = -1/4, x_2 = x_1 + \alpha_1 d_1 = (-1/2, -1/2)^T$ ，且 $\nabla f(x_2) = (0, 0)^T$ 。

5、设 H 是 n 阶具有不同特征值的对称正定矩阵，证明 H 的不同特征值对应的特征向量关于 H 是共轭的。

证明 设 d_1, d_2 是矩阵 H 属于不同特征值 λ_1, λ_2 的特征向量，即

$$H d_1 = \lambda_1 d_1, H d_2 = \lambda_2 d_2.$$

于是

$$d_2^T H d_1 = \lambda_1 d_2^T d_1, d_2^T H d_2 = \lambda_2 d_2^T d_2.$$

因此

$$(\lambda_1 - \lambda_2) d_2^T d_1 = 0.$$

因为 $\lambda_1 \neq \lambda_2$ ，所以 $d_2^T d_1 = 0$ 。于是 $d_2^T H d_1 = \lambda_1 d_2^T d_1 = 0$ 。因此 d_1, d_2 关于矩阵 H 是共轭的。

7、 设 H 是 n 阶对称正定矩阵，非零向量 $d_1, d_2, \dots, d_n$ 关于矩阵 H 共轭，证明

$$(1) x = \sum_{i=1}^n \frac{d_i^T H x}{d_i^T H d_i} d_i, \forall x \in R_n.$$

$$(2) H_{-1} = \sum_{i=1}^n \frac{d_i d_i^T}{d_i^T H d_i}.$$

证明 (1) 由假设， $d_1, d_2, \dots, d_n$ 是 R_n 中 n 个线性无关的向量，可作为一组基。于是 $\forall x \in R_n$,

可令

$$x = \sum_{j=1}^n \lambda_j d_j.$$

上式两端左乘 $d_i^T H$ ，则 $d_i^T H x = \lambda_i d_i^T H d_i$ ，因此

$$\lambda_i = \frac{d_i^T H x}{d_i^T H d_i}.$$

代入上式，得 $x = \sum_{i=1}^n \frac{d_i^T H x}{d_i^T H d_i} d_i, \forall x \in R_n$ 。

(2) 记 $H_{-1} = (\beta_1, \beta_2, \dots, \beta_n)$ ，由(1)所证， β_j 可表示为

$$\beta_j = \sum_{i=1}^n \frac{d_i^T H \beta_j}{d_i^T H d_i} d_i = \sum_{i=1}^n \frac{d_i d_i^T H \beta_j}{d_i^T H d_i}.$$

因此可以写成

$$(\beta_1, \beta_2, \dots, \beta_n) = \sum_{i=1}^n \frac{d_i d_i^T H (\beta_1, \beta_2, \dots, \beta_n)}{d_i^T H d_i} = \sum_{i=1}^n \frac{d_i d_i^T}{d_i^T H d_i},$$

即

$$H_{-1} = \sum_{i=1}^n \frac{d_i d_i^T}{d_i^T H d_i}.$$

8、 设 $p_1, p_2, \dots, p_n \in R_n$ 为一组线性无关向量， H 是 n 阶对称正定矩阵，令向量 d_k 为

$$d_k = \begin{cases} p_k, k=1, \\ p_k - \sum_{i=1}^k \frac{d_i^T H p}{d_i^T H d_i} d_i, k=2,3,\dots,n, \end{cases}$$

证明 $d_1, d_2, \dots, d_n$ 关于矩阵 H 共轭。

证明 利用数学归纳法 当 $k=2$ 时

$$\begin{aligned} d_1^T H d_2 &= p_1^T H \left(p_2 - \frac{d_1^T H p_1}{d_1^T H d_1} d_1 \right) = p_1^T H \left(p_2 - \frac{p_1^T H p_1}{p_1^T H p_1} p_1 \right) \\ &= p_1^T H p_2 - p_1^T H p_1 = 0. \end{aligned}$$

因此 d_1, d_2 关于矩阵 H 共轭。

设 $k < n$ 时结论成立, 即对所有不同的正整数 $j, t \leq k < n$, 有 $d_j^T H d_t = 0$ 。

当 $k=n$ 时, 有

$$\begin{aligned} d_j^T H d_n &= d_j^T H \left(p_n - \sum_{i=1}^n \frac{d_i^T H p_i}{d_i^T H d_i} d_i \right) = p_j^T H p_n - \sum_{i=1}^n \frac{d_j^T H p_i}{d_i^T H d_i} d_j^T H d_i \\ &= p_j^T H p_n - p_j^T H p_n = 0. \end{aligned}$$

因此, 当 $k=n$ 时结论成立, 于是 $d_1, d_2, \dots, d_n$ 关于矩阵 H 共轭。

补 1、设 $a \in R_n, \tau > 0$ 。试求下述问题的最优解

$$\min_{x \in R^n} f(x) = \frac{1}{2} \|x - a\|^2 + \tau \|x\|_2.$$

解 显然 $f(x)$ 在 R_n 上非负。整理 $f(x)$ 的表达式, 有

$$\begin{aligned} f(x) &= \frac{1}{2} \|x - a\|^2 + \tau \|x\|_2 \\ &= \frac{1}{2} \sum_{i=1}^n (x_i - a_i)^2 + \tau \sqrt{\sum_{i=1}^n x_i^2}. \end{aligned}$$

于是

$$\frac{\partial f(x)}{\partial x_i} = (x_i - a_i) + \frac{\tau x_i}{\sqrt{\sum_{i=1}^n x_i^2}} = (x_i - a_i) + \frac{\tau x_i}{\|x\|}.$$

因此 $f(x)$ 的稳定点满足方程组

$$\begin{cases} (x_1 - a_1) + \frac{\tau x_1}{\|x\|} = 0 \\ (x_2 - a_2) + \frac{\tau x_2}{\|x\|} = 0 \\ \dots \\ (x_n - a_n) + \frac{\tau x_n}{\|x\|} = 0 \end{cases}$$

于是

$$\begin{cases} x_1 = \frac{a_1 \|x\|}{\|x\| + \tau} \\ x_2 = \frac{a_2 \|x\|}{\|x\| + \tau} \\ \dots \\ x_n = \frac{a_n \|x\|}{\|x\| + \tau} \end{cases} \quad (*)$$

上面各式平方后累加得

$$\|x\|^2 = \left(\frac{\|a\| \|x\|}{\|x\| + \tau} \right)^2.$$

于是

$$\|x\| = \frac{\|a\| \|x\|}{\|x\| + \tau} \Rightarrow \|x\|^2 + (\tau - \|a\|)\|x\| = 0 \Rightarrow \|x\| = 0 \text{ 或 } \|x\| = \|a\| - \tau.$$

如果 $\|a\| \leq \tau$ ，则稳定点满足 $\|x\| = 0$ ，于是 $x^* = 0$ 。

如果 $\|a\| > \tau$ ，则稳定点满足 $\|x\| = 0$ 或 $\|x\| = \|a\| - \tau$ ，将其代入(*)式得 $\bar{x}^* = 0$ 或

$\hat{x}^* = \frac{a}{\|a\|}(\|a\| - \tau)$ 。二者对应的函数值分别是 $f(x^*) = \frac{\|a\|^2}{2}$ 与 $f(\hat{x}^*) = \tau\|a\| - \frac{\tau^2}{2}$ ，比较这两

个函数值，有

$$f(x^*) - f(\hat{x}^*) = \frac{\|a\|^2}{2} - \tau\|a\| + \frac{\tau^2}{2} = \frac{(\|a\| - \tau)^2}{2} > 0.$$

因此 $x^* = \frac{a}{\|a\|}(\|a\| - \tau)$ 。

综上，最优解是(可以再验证在稳定点处的 Hesse 是否正定：略)

$$x^* = \begin{cases} 0, & \text{if } \|a\| \leq \tau \\ \frac{a}{\|a\|} (\|a\| - \tau), & \text{if } \|a\| > \tau \end{cases} = \frac{a}{\|a\|} \max\{0, \|a\| - \tau\}.$$

补 2、设 $a \in R_n, \tau > 0$ 。试求下述问题的最优解

$$\min_{x \in R^n} f(x) = \frac{1}{2} \|x - a\|^2 + \tau \|x\|_1,$$

其中 $\|x\|_1 = \sum_{i=1}^n |x_i|$ 表示向量 x 的 1-范数。

解 这个问题属于不可微优化问题。显然 $f(x)$ 在 R_n 上非负，且

$$\begin{aligned} f(x) &= \frac{1}{2} \|x - a\|^2 + \tau \|x\|_1 \\ &= \frac{1}{2} \sum_{i=1}^n (x_i - a_i)^2 + \tau \sum_{i=1}^n |x_i| \\ &= \sum_{i=1}^n \left[\frac{1}{2} (x_i - a_i)^2 + \tau |x_i| \right] = \sum_{i=1}^n f(x_i). \end{aligned}$$

分析函数

$$\begin{aligned} f(x_i) &= \frac{1}{2} (x_i - a_i)^2 + \tau |x_i| \\ &= \frac{1}{2} x_i^2 - a_i x_i + \tau |x_i| + \frac{1}{2} a_i^2. \end{aligned}$$

如果 $x_i \geq 0$ ，则 $f(x_i) = \frac{1}{2} x_i^2 + (\tau - a_i) x_i + \frac{1}{2} a_i^2$ 。最优解为 $x_i^* = \begin{cases} a_i - \tau, & \text{if } a_i \geq \tau \\ 0, & \text{if } a_i < \tau \end{cases}$ ，最优

值为

$$f(x_i^*) = \begin{cases} a_i \tau - \frac{1}{2} \tau^2, & \text{if } a_i \geq \tau \\ \frac{1}{2} a_i^2, & \text{if } a_i < \tau \end{cases}$$

如果 $x_i \leq 0$ ，则 $f(x_i) = \frac{1}{2} x_i^2 - (\tau + a_i) x_i + \frac{1}{2} a_i^2$ 。最优解为 $\hat{x}_i^* = \begin{cases} a_i + \tau, & \text{if } a_i \leq -\tau \\ 0, & \text{if } a_i > -\tau \end{cases}$ ，最优

值为

$$f(\hat{x}_i^*) = \begin{cases} -a_i \tau - \frac{1}{2} \tau^2, & \text{if } a_i \leq -\tau \\ \frac{1}{2} a_i^2, & \text{if } a_i > -\tau \end{cases}$$

(1) 当 $a_i \geq \tau$ 时, 比较 $a_i \tau - \frac{1}{2} \tau^2$ 与 $\frac{1}{2} a_i^2$ 的大小。做差得

$$\frac{1}{2} a_i^2 - \left(a_i \tau - \frac{1}{2} \tau^2 \right) = \frac{1}{2} (a_i - \tau)^2 \geq 0.$$

因此 $x_i^* = a_i - \tau$ 。

(2) 当 $-\tau < a_i < \tau$ 时, 函数值恒等于 $\frac{1}{2} a_i^2$, 此时 $x_i^* = 0$ 。

(3) 当 $a_i \leq -\tau$ 时, 比较 $\frac{1}{2} a_i^2$ 和 $-a_i \tau - \frac{1}{2} \tau^2$ 的大小。做差得

$$\frac{1}{2} a_i^2 - \left(-a_i \tau - \frac{1}{2} \tau^2 \right) = \frac{1}{2} (a_i + \tau)^2 \geq 0.$$

因此 $x_i^* = a_i + \tau$ 。

综上, 得最优解

$$x_i^* = \begin{cases} a_i - \tau, & \text{if } a_i \geq \tau \\ 0, & \text{if } -\tau < a_i < \tau \\ a_i + \tau, & \text{if } a_i \leq -\tau \end{cases} = \text{sign}(a_i) \max\{0, |a_i| - \tau\}.$$

补 3、设 $Y \in R_{n_1 \times n_2}, \tau > 0$ 。试求下述问题的最优解

$$\min_{X \in R^{n_1 \times n_2}} F(X) = \frac{1}{2} \|X - Y\|_F^2 + \tau \|X\|_*$$

其中 $\|X\|_*$ 表示矩阵 X 的核范数, 是其所有奇异值的和。